







detr 模型基本流程图.

backbone 部分

$X = (bs, channel, H, W)$



Resnet 50 的前 48 层, 后两层冻结



1x1 卷积核降通道



$X = (bs, h \times w, embed_dim)$

$Mask = (bs, H, W)$



最近邻插值下采样



$mask_down = (bs, h \times w)$


$h = H/32, w = W/32, embed_dim = 256.$


$bs = batch_size.$




$x, h, w, mask_down.$

Encoder部分: 由 b 个 Encoder block 层构成.





知道 EncoderBlock 原理后, 进行叠加 6 层.



6 层 Encoder 的最终输出, 即 memory.

每层 $X + \text{pos} = Q = K$ 加位置编码. 因此 pos 是复用的.
 $X = V$ mask down 也是复用的. 每层都加入

Decoder部分. 由 6个 Decoder Block 层组成.

最开始: 进行目标查询全零初始化、查询位置初始化



$queries = (bs, num_queries=100, embed_dim=256)$

$query_pos = (bs, num_queries=100, embed_dim=256)$

注意, 要进入 decoder 的有, queries, query_pos.

memory, memory_pos = encoder_pos, mask_down

$(bs, num_tokens=h \times w, embed_dim=256)$


$(bs, h \times w)$

Decoder Block 组成.

$Q = K = \boxed{queries} + \boxed{query_pos}$, $V = queries$.

→ 最开始全零.

Multihed Self Attention 多头自注意力 ⇒ 无掩码.




Dropout 层 3

残差连接

Layer Norm 层 3

queries 输出 $\Rightarrow$ 不再是全零了。

知道 DecoderBlock 原理后, 重叠 6 次形成一完整的 Decoder



6层 Decoder 的最终输出, 即 output = queries 6.

Decoder 中每个 DecoderBlock, 自注意力时作 Q = queries + query-pos

发生了更新! $k = \text{queries} + \text{query-pos}$
 $V = \text{queries}$


交叉注意力时作 $Q = \text{queries} + \text{query-pos}$

$k = \text{memory} + \text{encoder-pos}$

$V = \text{memory}$

回归头部分 $\Rightarrow$ 对应 Decoder Block 层数.

独立初始化分类头. 边界框头.



匈牙利匹配: 100个预测框与 N 真实框作匹配,

$$\text{Cost} = \text{cls-cost} + 5 \times \text{l1-cost} + 2 \times \text{giou-cost}.$$

最终 $\text{total-loss} =$ 各层独立匹配后 loss 之和.

$$\text{每层 Loss} = \text{cls-loss} + 5 \times \text{l1-loss} + 2 \times \text{giou-loss}.$$

